

12 DE MAYO DE 2025



Optimización de un Portafolio de Inversión mediante Particle Swarm Optimization (PSO)

JARED ALEJANDRO JOSE HERNANDEZ FIGUEROA – JESÚS ISAÍAS RUÍZ MALDONADO

ENES UNAM

IO

Introducción

En este proyecto buscaremos desarrollar un portafolio de inversión mediante un modelo acorde a la transición tecnológica que vivimos hoy día (uso de IA), para ello utilizaremos un interesante algoritmo conocido como Particle Swarm Optimization o, por sus siglas, PSO. Este algoritmo es una de las múltiples herramientas de optimización que existen en la actualidad.

El modelo desarrollado será aplicable para los activos financieros que el usuario desee, de manera que se adapte a lo que el usuario mismo busque. A través de la estimación de rendimientos y volatilidades, se emplea PSO para buscar una asignación óptima que maximice una función objetivo basada en el retorno, riesgo y aversión al riesgo. Este método explora múltiples soluciones, muy similar a la inteligencia artificial, mas no es inteligencia artificial.

Hipótesis

Si se aplica el algoritmo PSO para determinar la mejor distribución de capital en un portafolio financiero, tomando en cuenta parámetros como el rendimiento esperado, la volatilidad de cada activo y la aversión al riesgo del inversor será posible construir un portafolio personalizado que optimice la relación entre retorno y riesgo, garantizando rentabilidad en la inversión.

Objetivo

Desarrollar un modelo de optimización basado en el algoritmo PSO para determinar la asignación óptima (mejor solución = mejor posición global (gbest)) de capital en un portafolio financiero, utilizando el rendimiento esperado, volatilidad, aversión al riesgo, con el fin de maximizar el retorno ajustado a la aversión al riesgo de cada inversor.

Marco Teórico

Particle Swarm Optimization (PSO)

El algoritmo PSO, propuesto por Kennedy y Eberhart en 1995, es una técnica de optimización basada en el comportamiento colaborativo de partículas en un espacio de búsqueda. En este contexto financiero, PSO se aplica para determinar dinámicamente la distribución de activos en el portafolio, buscando la combinación que maximiza el rendimiento esperado, mientras minimiza la volatilidad.

Según Eberhart y Shi (2001), PSO es particularmente útil en problemas donde las funciones objetivo son complejas y no lineales. A diferencia del método Simplex, que se basa en programación lineal, PSO permite encontrar soluciones óptimas en escenarios con múltiples variables interdependientes, como la diversificación de inversiones.

Las partículas (posibles soluciones dentro del espacio de búsqueda y se representan como vectores) tienen características importantes como lo son:

- ✚ Coeficiente cognitivo: Permite a la partícula buscar su mejor solución propia, cada partícula encuentra una solución y buscara refinarla, determina la (pBest), es decir, la mejor posición o solución de esa partícula.
- ✚ Coeficiente Social: Es la atracción de las partículas hacia la mejor solución global, es decir, la atracción hacia la solución de la partícula que ha encontrado la mejor solución entre todas.
- ✚ Velocidad: Es la velocidad con que la partícula recorre el espacio de búsqueda, influye en su capacidad de exploración y explotación. Por tanto, si es muy lenta puede no abarcar todas las soluciones, si es muy rápida, puede saltarse posibles soluciones.
- ✚ Exploración: Capacidad de buscar múltiples soluciones.
- ✚ Explotación: Capacidad de mejorar su propia solución.

En el proceso cada partícula actualiza su velocidad de acuerdo con la siguiente formula:

$$v_i(t + 1) = w \cdot v_i(t) + c_1 \cdot r_1 \cdot (pBest_i - x_i(t)) + c_2 \cdot r_2 \cdot (gBest - x_i(t))$$

Donde:

- $v_i(t)$: velocidad actual de la partícula.
- $x_i(t)$: posición actual de la partícula.
- w : **coeficiente de inercia o velocidad** (influencia de su movimiento anterior).
- c_1 : **coeficiente cognitivo** (peso de su mejor solución personal).
- c_2 : **coeficiente social** (peso de la mejor solución del enjambre).
- r_1, r_2 : valores aleatorios entre 0 y 1 (generan aleatoriedad).
- pBest: mejor posición que ha tenido la partícula.
- gBest: mejor posición encontrada por todo el enjambre.

Posteriormente actualiza su posición:

$$x_i(t + 1) = x_i(t) + v_i(t + 1)$$

Y finalmente se encoge aquella partícula con la mejor solución.

Rendimiento y Volatilidad Anualizados

El rendimiento y la volatilidad anualizados son indicadores clave para evaluar la rentabilidad y el riesgo de un portafolio a largo plazo. El rendimiento anualizado se calcula multiplicando el rendimiento medio diario por el número de días hábiles en un año (252), mientras que la volatilidad anualizada se obtiene multiplicando la desviación estándar de los rendimientos diarios con la raíz cuadrada de 252.

Como señalan Bodie, Kane y Marcus (2014), “la comparación entre rendimiento y riesgo es fundamental para construir estrategias de inversión eficientes”. En este proyecto, estas métricas se usan para definir una función de costo que permita ajustar el portafolio según el nivel de aversión al riesgo del inversionista.

Aversión al riesgo: Es la preferencia de inversiones con baja incertidumbre, en otras palabras, que tanto te importa el riesgo, para uso practico estará dada entre 0 y 1, siendo 0, nula aversión al riesgo, y 1, total aversión al riesgo.

Metodología

El proyecto se realizó en Python, utilizando las siguientes librerías:

-  Yfinance: Permite obtener los precios de cierre de cada activo.
-  Numpy y pandas: Permiten el análisis numérico y operaciones matemáticas.
-  Matplotlib; Permite elaborar graficas.
-  Pyswarms: Permite usar el algoritmo PSO.

Descarga de datos: Se obtienen los precios de cierre de los activos desde Yahoo Finance en el período 2023-04-01 a 2025-04-01.

El periodo de dos años nos puede dar una idea de la situación financiera de las empresas, en especial porque se ve mayor estabilidad financiera posterior a la pandemia.

Selección de Activos:

Para este portafolio seleccionamos a dos grandes empresas de tecnología como lo es Nividea (NVDA), y Microsoft (MSFT), tres de sectores básicos: Walmart (WMT), Coca cola (KO), Pfizer (PFE), y por ultimo un activo de riesgo y gran potencial a largo plazo: Bitcoin (BTC-USD), con el fin de diversificar las acciones en diferentes sectores, cabe mencionar que tanto para las empresas tecnológicas como Bitcoin se prevén posibles crecimientos, mientras que, los sectores básicos, siendo la mayoría del portafolio, muestran estabilidad a lo largo del tiempo.

Cálculo de métricas financieras: Se generan los rendimientos diarios, el rendimiento medio y la volatilidad. Posteriormente se calcula de manera anualizada multiplicando *252 días hábiles. Para ello se utilizan las funciones de Python: returns, returns.mean(), returns.std(), returns.cov().

Construcción de la función objetivo: $(-\text{retorno} * (1 - \lambda) + \lambda * \text{riesgo})$, donde λ representa la aversión al riesgo.

Python minimiza la función, para ello se cambian los signos, entonces tenemos como resultado dos partes de la función, la primera nos representa el retorno o rendimientos, y después del signo +, funciona como una penalización al retorno dado el riesgo y aversión al riesgo, de tal manera que a mayor lambda se prioriza el riesgo y se obtiene menos rendimientos, e inversamente a una menor lambda permite mayor rendimiento y la penalización de riesgo es menor, por tanto, resulta ser más alto. Para este caso se utilizará una aversión al riesgo de 0.6, de manera que estará en un punto intermedio, ligeramente inclinado a un perfil conservador.

Antes de continuar es importante mencionar algunas restricciones importantes del portafolio.

Restricciones del Modelo

El portafolio debe cumplir con las siguientes restricciones:

1. Todos los pesos deben ser positivos.
2. No se permite venta en corto (La venta en corto es una venta que realizas con la suposición de que un determinado activo irá a la baja. Esto se puede realizar a manera de mitigar pérdida, o con el objetivo de vender “caro” y comprar “barato”).
3. La suma de los pesos debe ser igual a 1: es decir, la inversión se distribuye completamente.
4. Diversificación mínima: A manera de que el resultado sea el óptimo, no se establecieron márgenes porcentuales mínimos en la distribución de pesos, pero se recomienda optar por al menos 5 activos distintos. Como dice Warren Buffet: ‘No hay que poner todos los huevos en una sola canasta’.

Definición de la Función Objetivo

La función objetivo se expresa de la siguiente manera:

$$\text{Funcion objetivo} = - \sum_i w_i \mu_i * (1 * \lambda) - + \lambda \sqrt{w^t C w}$$

Donde:

- ❖ w_i : Peso del activo i en el portafolio.
- ❖ μ_i : Rendimiento esperado del activo i .
- ❖ C : Matriz de covarianza de los activos.
- ❖ λ : Parámetro de aversión al riesgo.
- ❖ w : Vector de pesos del portafolio.
- ❖ w^t : Transpuesta del vector de pesos.
- ❖ El primer término $(-\sum w_i \cdot \mu_i \cdot (1 - \lambda))$ representa el rendimiento esperado del portafolio.
- ❖ El segundo término $(\lambda \cdot \sqrt{(w^t \cdot C \cdot w)})$ representa el riesgo total del portafolio (volatilidad), ajustado por el parámetro de aversión al riesgo λ , penalizando el rendimiento.

Posterior a crear la función se creó un envoltorio para guardar todos los posibles resultados de esas partículas y posterior poderlos usar en la función PSO.

Se configura el algoritmo, para este portafolio elegimos un cognitivo y social de 1.5 para darle la misma importancia a la mejor solución de cada partícula y la de otras partículas, así como una velocidad intermedia de .7, los rangos de coeficientes cognitivos varían, diversas fuentes bibliográficas difieren en un rango exacto, pero en general se pueden observar rangos para los coeficientes de 0 a 2 y para la velocidad de .4 a 1.2, dependiendo la bibliografía consultada.

Una vez configurado, se emplea la función de python: `optimizer = GlobalBestPSO(n_particles=100, dimensions=n_assets, options=options, bounds=bounds)best_cost, best_pos= optimizer.optimize(f, iters=500)`

En esta función de Python se define el número de partículas (100), iteraciones (500), dimensiones (cantidad de activos), options (Coeficientes y velocidad antes configuradas), bounds (Calcular la inversión del 100% de activos), y nos proporcionara los mejores resultados tanto de los pesos de los activos como del rendimiento y riesgo anual del portafolio.

Por último, se utilizan dos códigos, uno para imprimir los resultados óptimos, y el otro para graficar los pesos de cada activo.


Además, agregamos el cálculo del índice de sharpe como sugerencia de nuestro profesor Francisco Javier Pedroza Castro, el cual mide que tanto se justifica el riesgo dado el rendimiento, siendo mayor a 1, un buen portafolio, es decir, el rendimiento del portafolio justifica el riesgo, y menor a 1, el rendimiento del portafolio no justifica el riesgo.

Resultados

Evidentemente, al ser un modelo que no se adapta únicamente a los activos sino también a la aversión al riesgo del usuario, existirán un sin fin de resultados óptimos posibles. Nosotros ajustamos los parámetros más acordes a nuestras necesidades y obtuvimos el siguiente portafolio:

Asignación Óptima de Capital

Activo	Peso Óptimo (%)
BTC-USD	35.87
KO	22.22
MSFT	14.21
NVDA	0.58
PFE	26.37
WMT	0.76



Rendimiento y riesgo:

Rendimiento esperado anualizado: 33.88%
Riesgo (desviación estándar anual): 16.95%

Y un índice de sharpe de:

Índice de Sharpe del portafolio:

1.4676712705219557

El portafolio tiene un rendimiento superior que justifica el riesgo.

Conclusión de nuestro resultado y proyecto.

Este proyecto ha demostrado la utilidad de PSO para la optimización de portafolios de inversión, logrando una distribución eficiente del capital entre distintos activos financieros. Como resultado, el algoritmo PSO con nuestras configuraciones y selección de activos nos proporciona un rendimiento anual de 33.88.% con un riesgo de 16.95%, y un índice de Sharpe de 1.46. Podemos resaltar que un 49.35% del portafolio está distribuido en el sector básico, siendo casi de la misma proporción Coca cola y Pfizer, garantizando así una estabilidad confiable a largo plazo. Además, aproximadamente un 15% en el sector tectológico, y el 35.87% restante se encuentra en Bitcoin, la criptomoneda de mayor importancia. El rendimiento anual esperado refleja una estrategia que prioriza retornos consistentes sin aumentar excesivamente la exposición al riesgo. Este resultado sería bastante bueno para un perfil con una aversión al riesgo intermedia ya que posee estabilidad relativamente segura, posibles rendimientos derivados de innovaciones tecnológicas de las máximas potencias de dicho sector y posibles crecimientos exponenciales de un mercado Over The Counter.

Siempre es oportuno recalcar que la selección de múltiples activos permite una mitigación efectiva del riesgo, mientras que la optimización algorítmica garantiza que la inversión se distribuya de manera óptima según la aversión al riesgo del inversor. La integración de PSO en la gestión de portafolios demuestra ser una herramienta valiosa para asignar capital de manera estratégica, maximizando el rendimiento y minimizando el riesgo a través de una asignación diversificada. Este enfoque puede extenderse a diferentes conjuntos de activos y ajustarse a perfiles de inversión más conservadores o agresivos, ofreciendo flexibilidad en la toma de decisiones financieras de cada persona.

Aunque, siendo el PSO un montón de soluciones, no quiere decir que encontramos la mejor, si usted realiza un portafolio con este algoritmo podría modificar las veces que quiera el numero de partículas, los coeficientes, la velocidad, las iteraciones, al fin de cuentas el PSO nos da un sin fin de soluciones, y una combinación correcta del algoritmo, fechas, activos, puede dar un gran resultado, de eso no hay duda.

Como último comentario, nos gustaría mencionar un poco nuestra experiencia en la elaboración de este proyecto la cual fue gratamente positiva. Como fue mostrado al principio del trabajo, nuestro objetivo era simplemente la elaboración de un portafolio de inversión, pero esta vez buscamos variar un poco de lo cotidiano. El algoritmo PSO nos pareció muy interesante y distinto de lo habitual como lo es el uso de la teoría Markowitz. Al ser un tema un poco fuera de nuestro dominio, el resultado nos pareció mejor al esperado, tomando como punto de referencia portafolios elaborados por nosotros con anterioridad, los resultados

(pesos de los activos) nos parecieron bastante coherentes con los datos utilizados y demás externalidades a tomar en cuenta en la distribución de una inversión. Consideramos que este modelo puede ser realmente aplicado.

Referencias

-  **Eberhart, R. & Shi, Y. (2001).** *Particle swarm optimization: Developments, applications and resources*. Proceedings of the 2001 Congress on Evolutionary Computation (Vol. 1, pp. 81-86). IEEE.
-  Bodie, Z., Kane, A., & Marcus, A. J. (2014). *Investments*. McGraw-Hill Education.
-  Clases de Investigación de operaciones (“IO”) con el profesor Francisco Javier Pedroza Castro.